

Java Memory Model



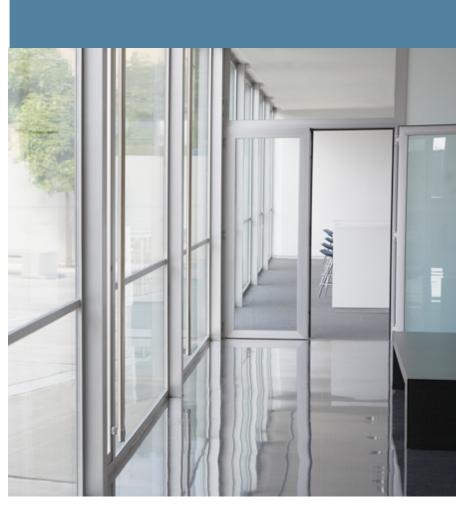
Sergey Kuksenko Java Platform Performance The following is intended to outline our general product direction. It is intended for information purposes only, and may not be incorporated into any contract. It is not a commitment to deliver any material, code, or functionality, and should not be relied upon in making purchasing decisions.

The development, release, and timing of any features or functionality described for Oracle's products remains at the sole discretion of Oracle.



Agenda

- Для чего?
- Из-за чего?
- Как
- Примеры
- Сколько стоит





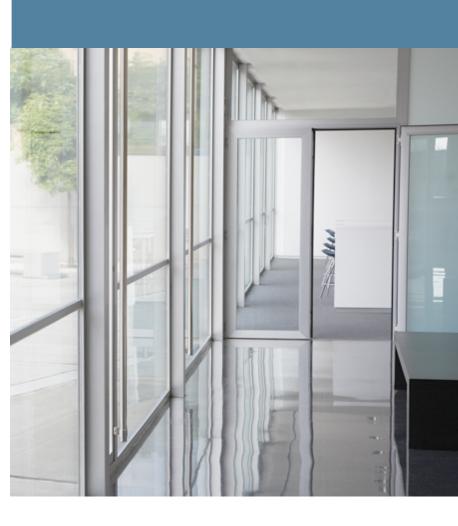
"Requirements for Programming Language Memory Models" Jeremy Manson and William Pugh

"If programmers don't know what their code is doing, programmers won't be able to know what their code is doing wrong."



Agenda

- Для чего?
- Из-за чего?
- Как
- Примеры
- Сколько стоит





Memory wall

- 1980
 - скорость одной операции CPU ~ скорость одного доступа к памяти
- 2010
 - скорость CPU выросла более чем в 10000 раз
 - − скорость памяти выросла в ~10 раз





The Free Lunch Is Over

- 1980
 - скорость одной операции CPU ~ скорость одного доступа к памяти
- 2010
 - скорость CPU выросла более чем в 10000 раз
 - − скорость памяти выросла в ~10 раз



2005 Herb Sutter "The Free Lunch Is Over"

http://www.gotw.ca/publications/concurrency-ddj.htm

увеличиваем количество CPU



в итоге

- Сложная архитектура современных СРИ
 - многоядерность
 - OoO (Out of Order execution)
 - Store buffers (+ store forwarding)
 - Сложная иерархия кешей
 - Протоколы когерентности кешей (MESI, MOESI, MESIF, ...)
 - NUMA, ccNUMA
- "Умные" компиляторы



Начальные значения: A == B == 0

Thread 1	Thread 2
r1 = B; A = 1;	r2 = A; $B = 1;$



Начальные значения: A == B == 0

Thread 1	Thread 2
r1 = B; A = 1;	r2 = A; $B = 1;$

Какие значения могут быть для *r1* и *r2*?



Начальные значения: A == B == 0

Thread 1	Thread 2
r1 = B; A = 1;	r2 = A; $B = 1;$

Какие значения могут быть для *r1* и *r2*?



Начальные значения: A == B == 0

Thread 1	Thread 2
r1 = B; A = 1;	r2 = A; B = 1;
	Reordering

Какие значения могут быть для *r1* и *r2*?



Начальные значения: A == B == 0

Thread 1	Thread 2	Thread 3	
A = 1;	while(A != 1) ; B = 1;	while(B != 1); r1 = A;	



Начальные значения: A == B == 0

Thread 1	Thread 2	Thread 3	
A = 1;	while(A != 1) ; B = 1;	while(B != 1); r1 = A;	



Начальные значения: A == B == 0

Thread 1	Thread 2	Thread 3	
A = 1;	while(A != 1) ; B = 1;	while(B != 1) ; r1 = A;	Результат: r1 == 1 или (or) r1 == 0

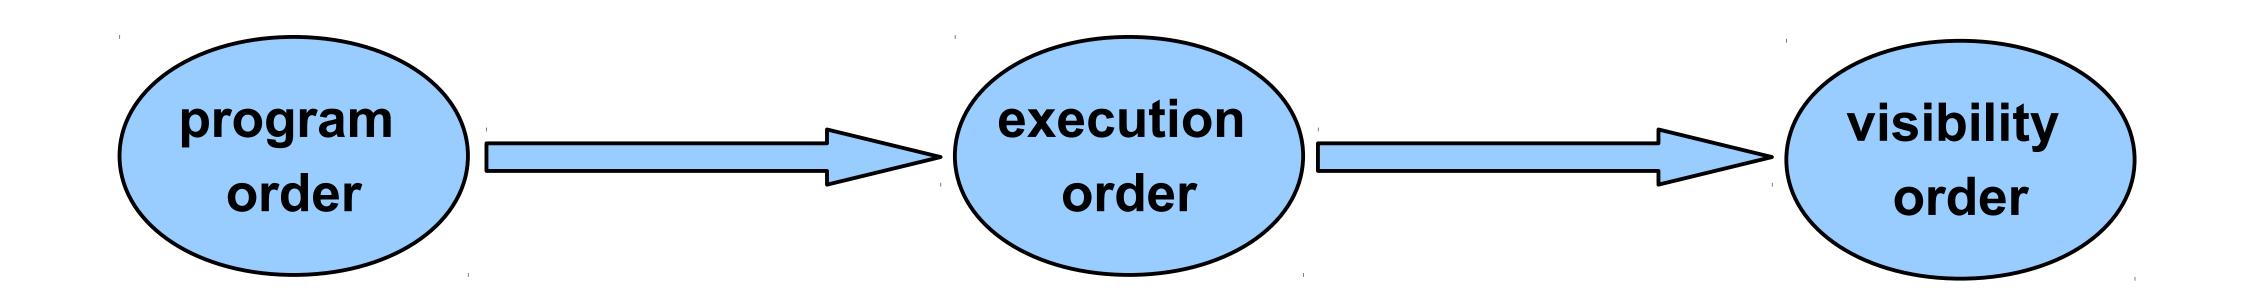
Visibility

Возможно:

Thread 2 видит write A первым потоком ПЕРЕД тем как увидит write A

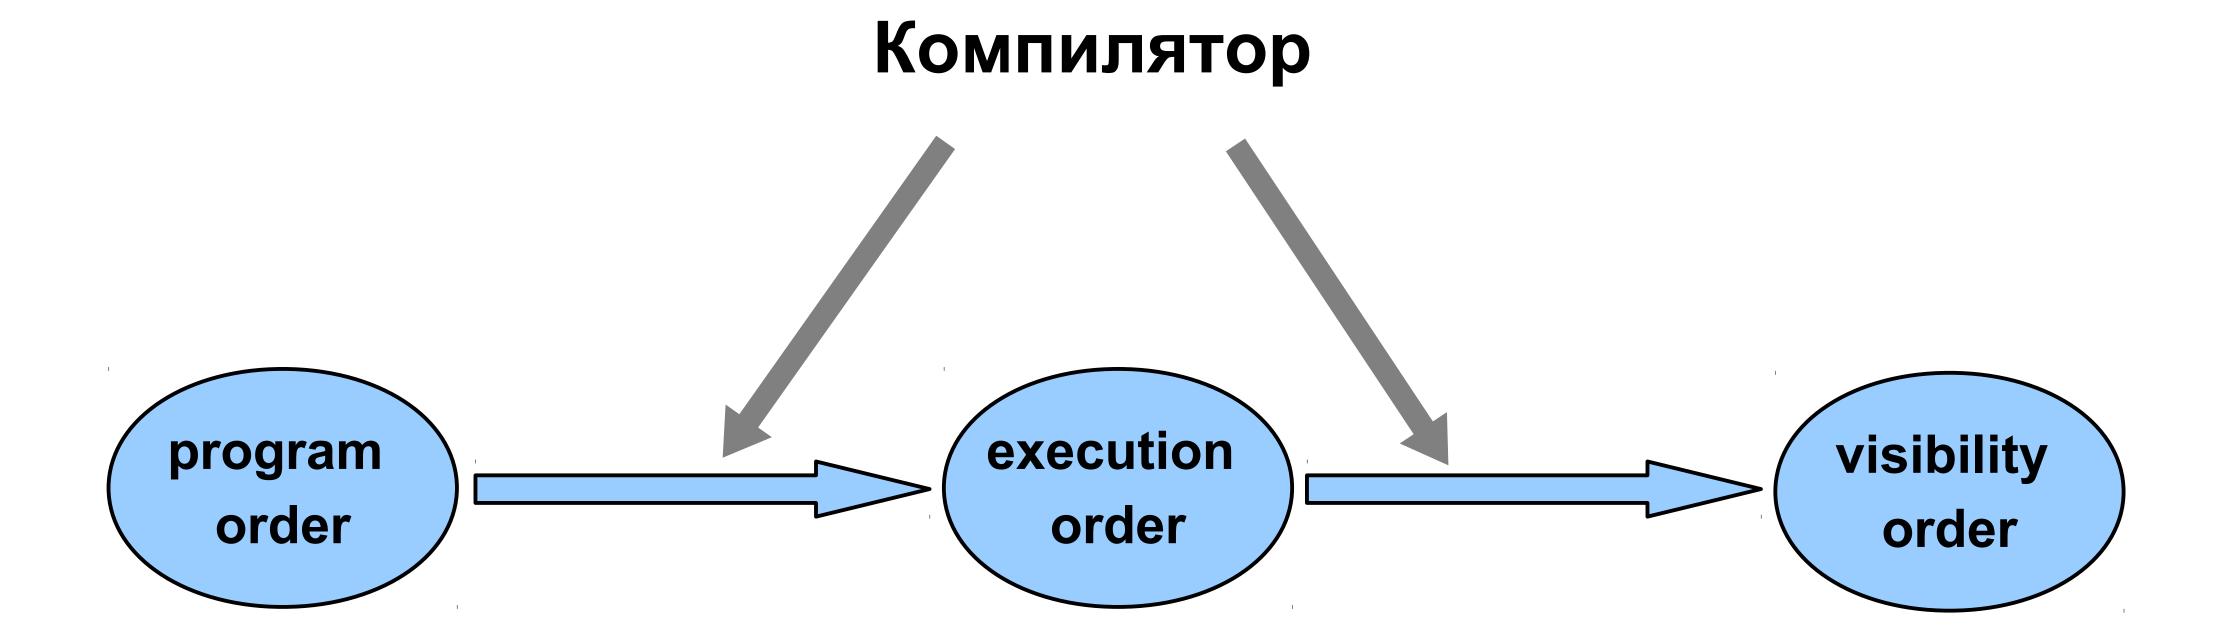


Кто виноват?



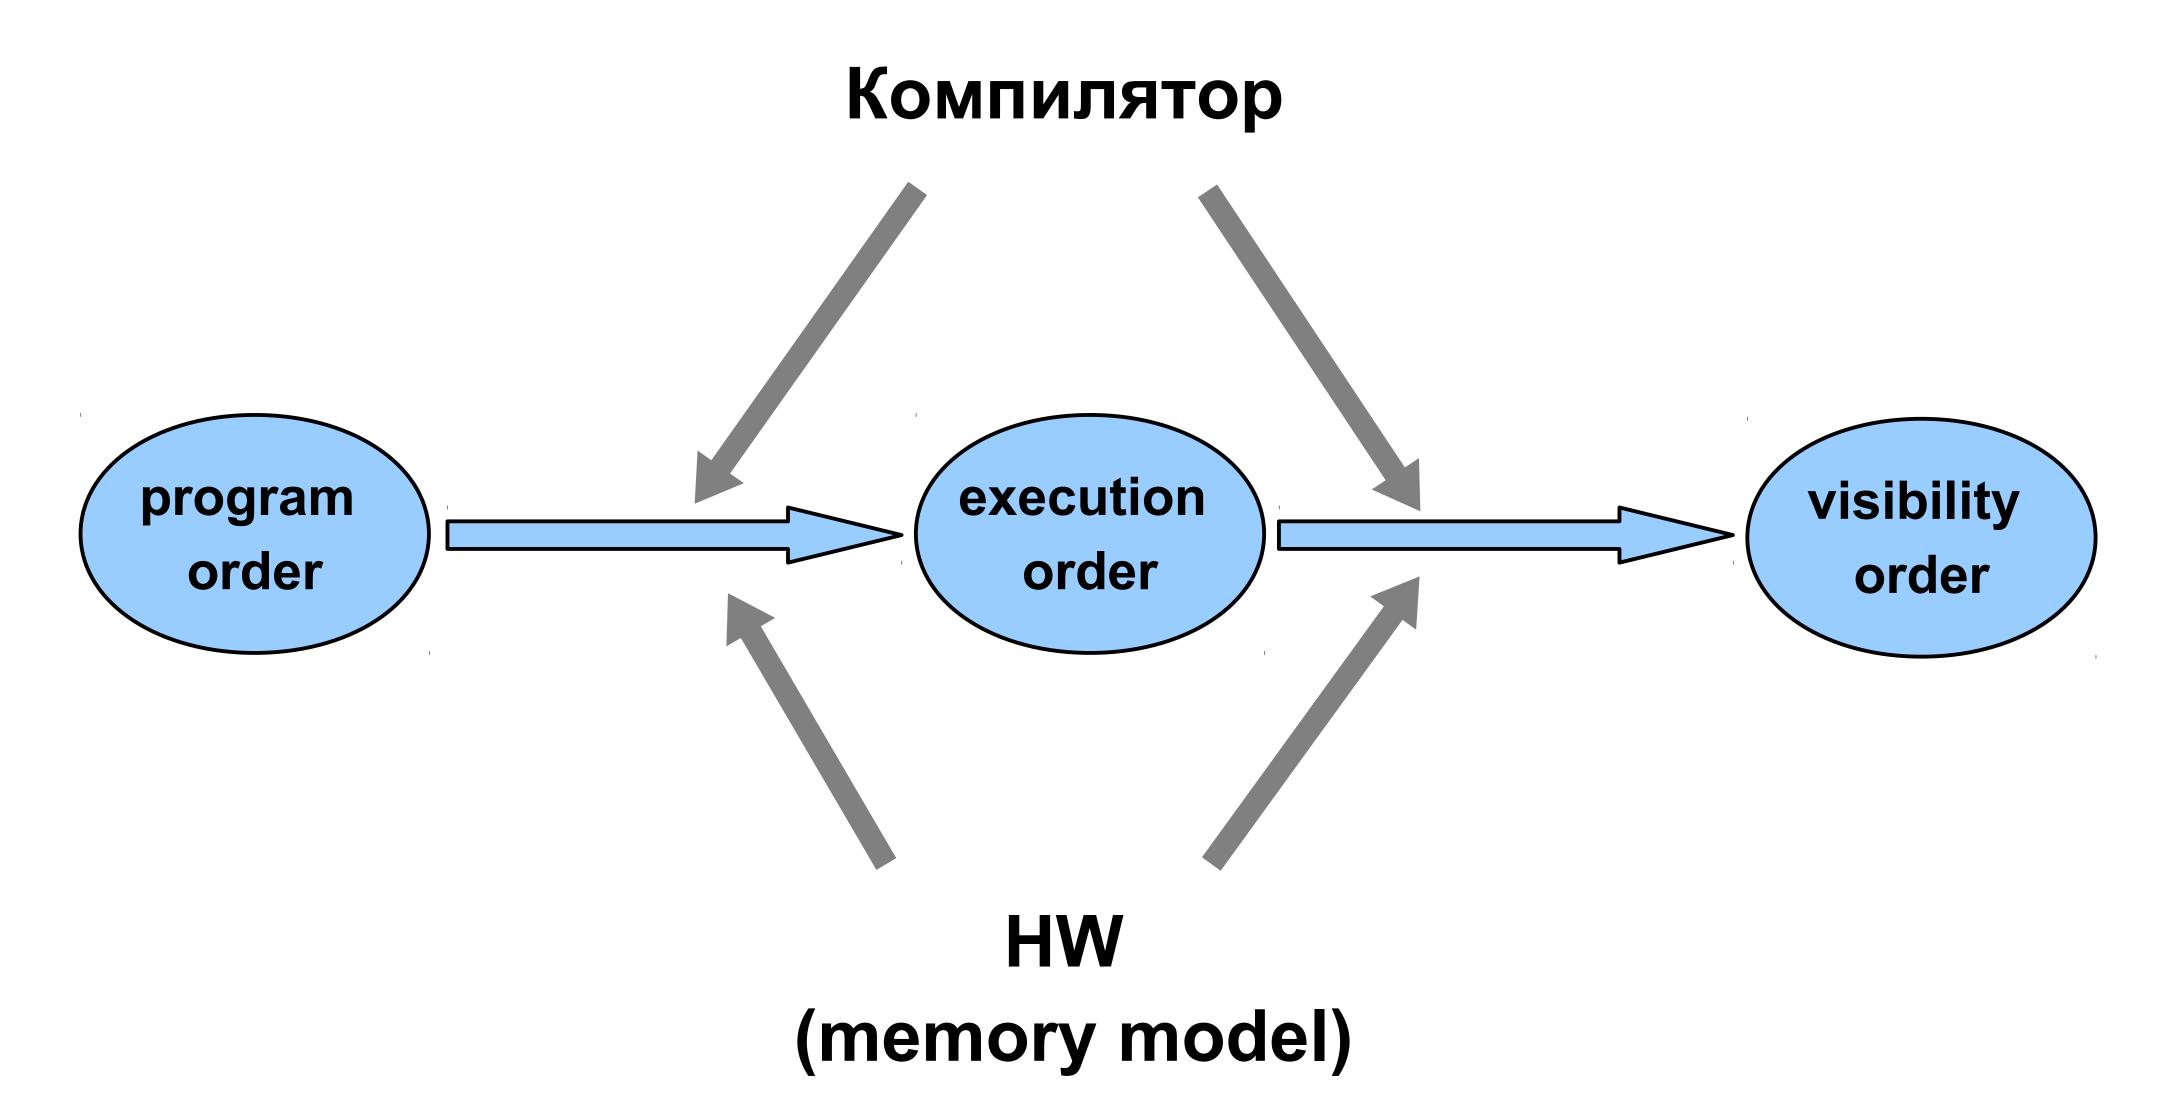


Кто виноват?





Кто виноват?





Def: "операция завершилась"



Def: "операция завершилась"

- А) Началось исполнение следующей операции.
- Б) Значение оказалось в основной памяти.
- Ц) Результат записи виден в точке использования.



Def: "операция завершилась"

Как определить, что "операция завершилась"?

- Л) Началось исполнение следующей сперации.
- 5) Значение оказалось в основной памяти.
- Ц) Результат записи виден в точке использования.



Atomicity

int A = 0xABCDFFFF;

Нарушения атомарности:

- Целевая платформа не содержит операции 32—битной записи (e.g. только 16 бит) => раздельная запись старшей и младшей частей.
- х86: адрес А не выровнен относительно размера.



Основные свойства модели памяти

• Atomicity (атомарность)

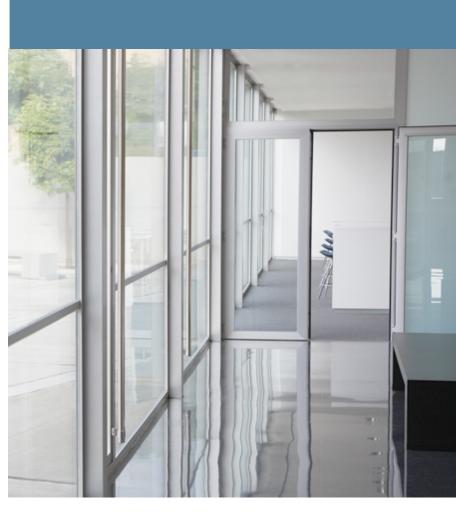
• Visibility (видимость)

• Ordering (порядок)



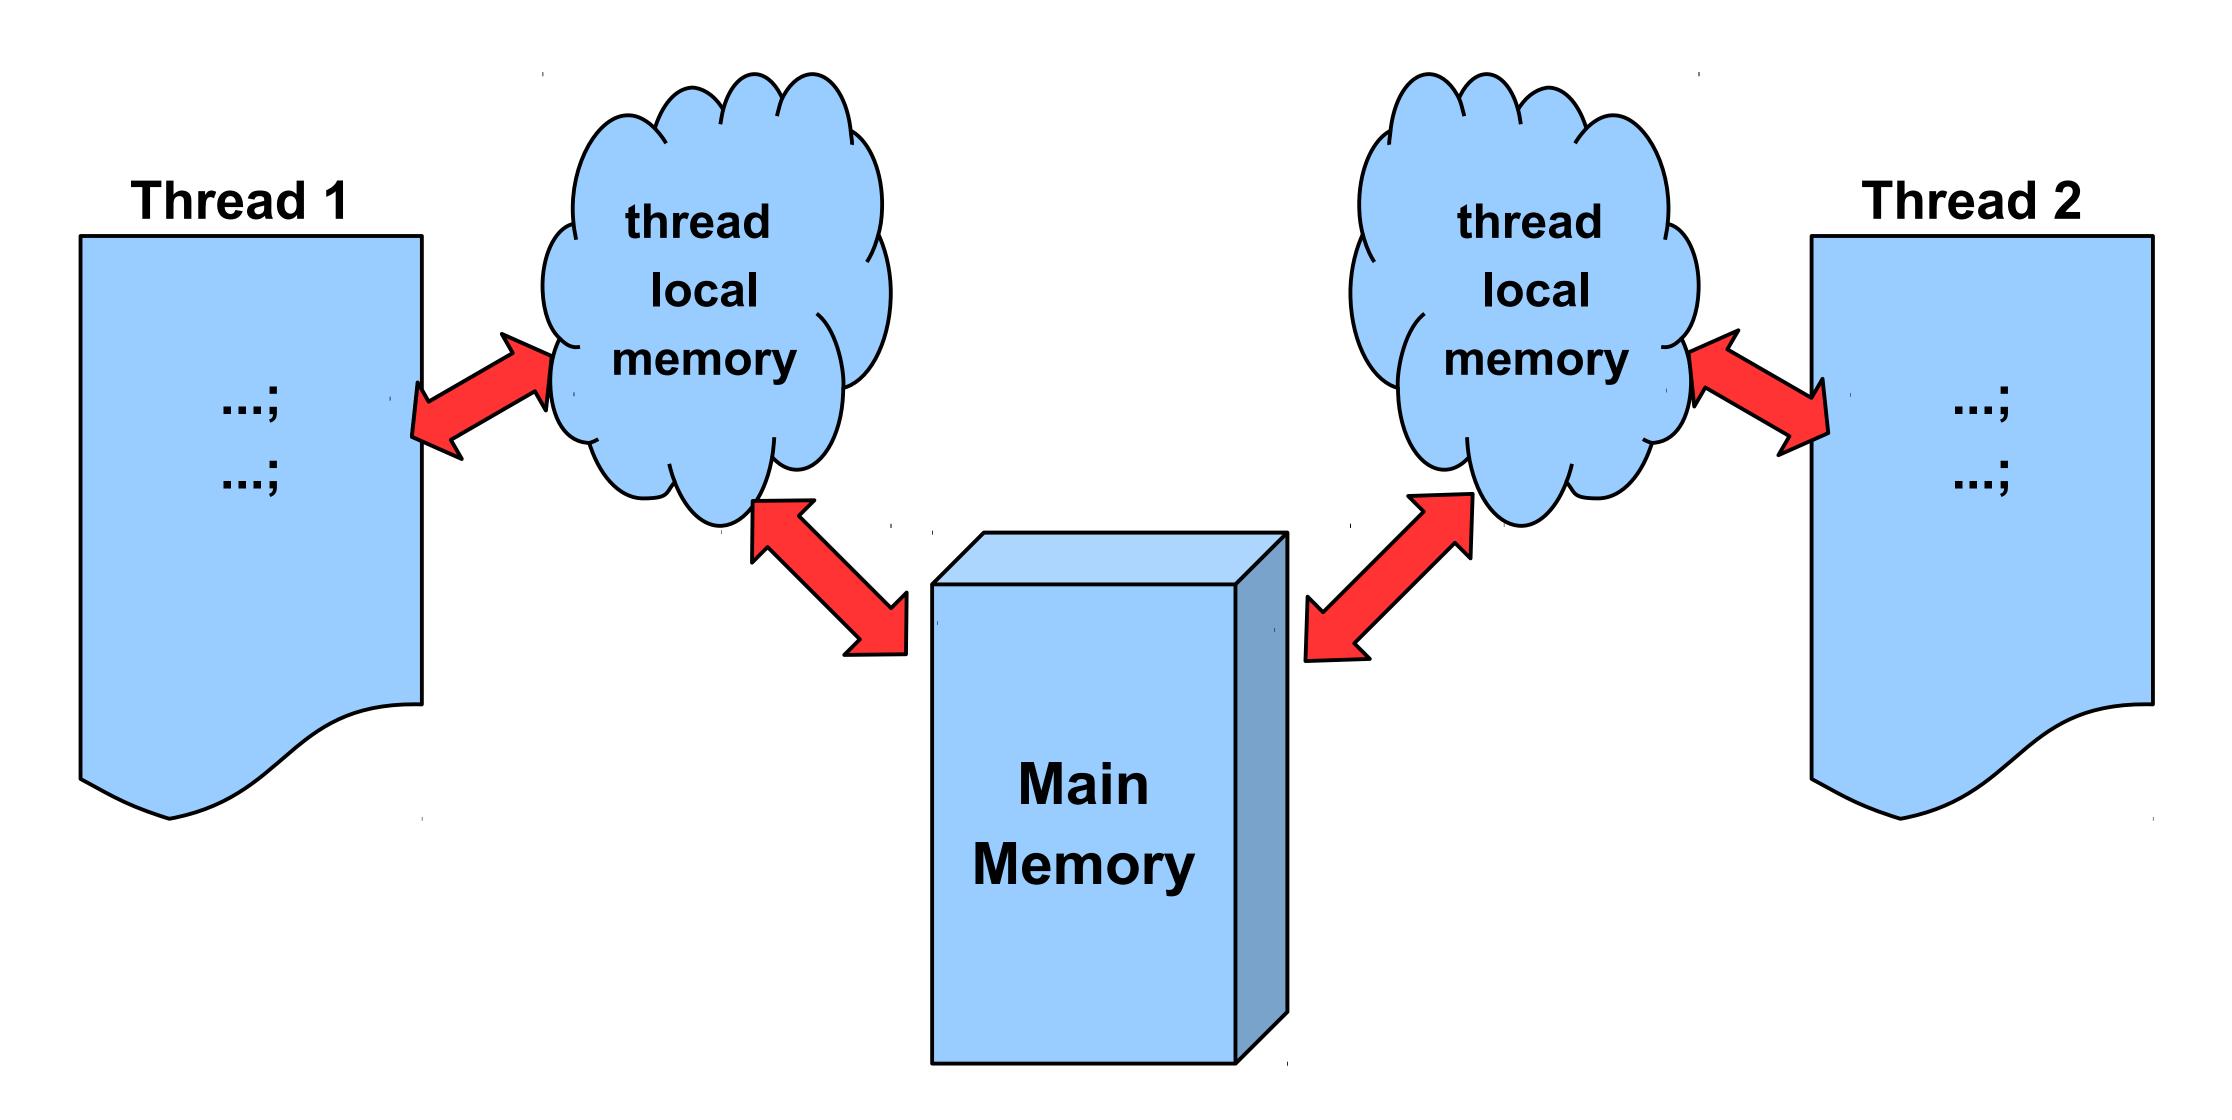
Agenda

- Для чего?
- Из-за чего?
- Как!
- Примеры
- Сколько стоит



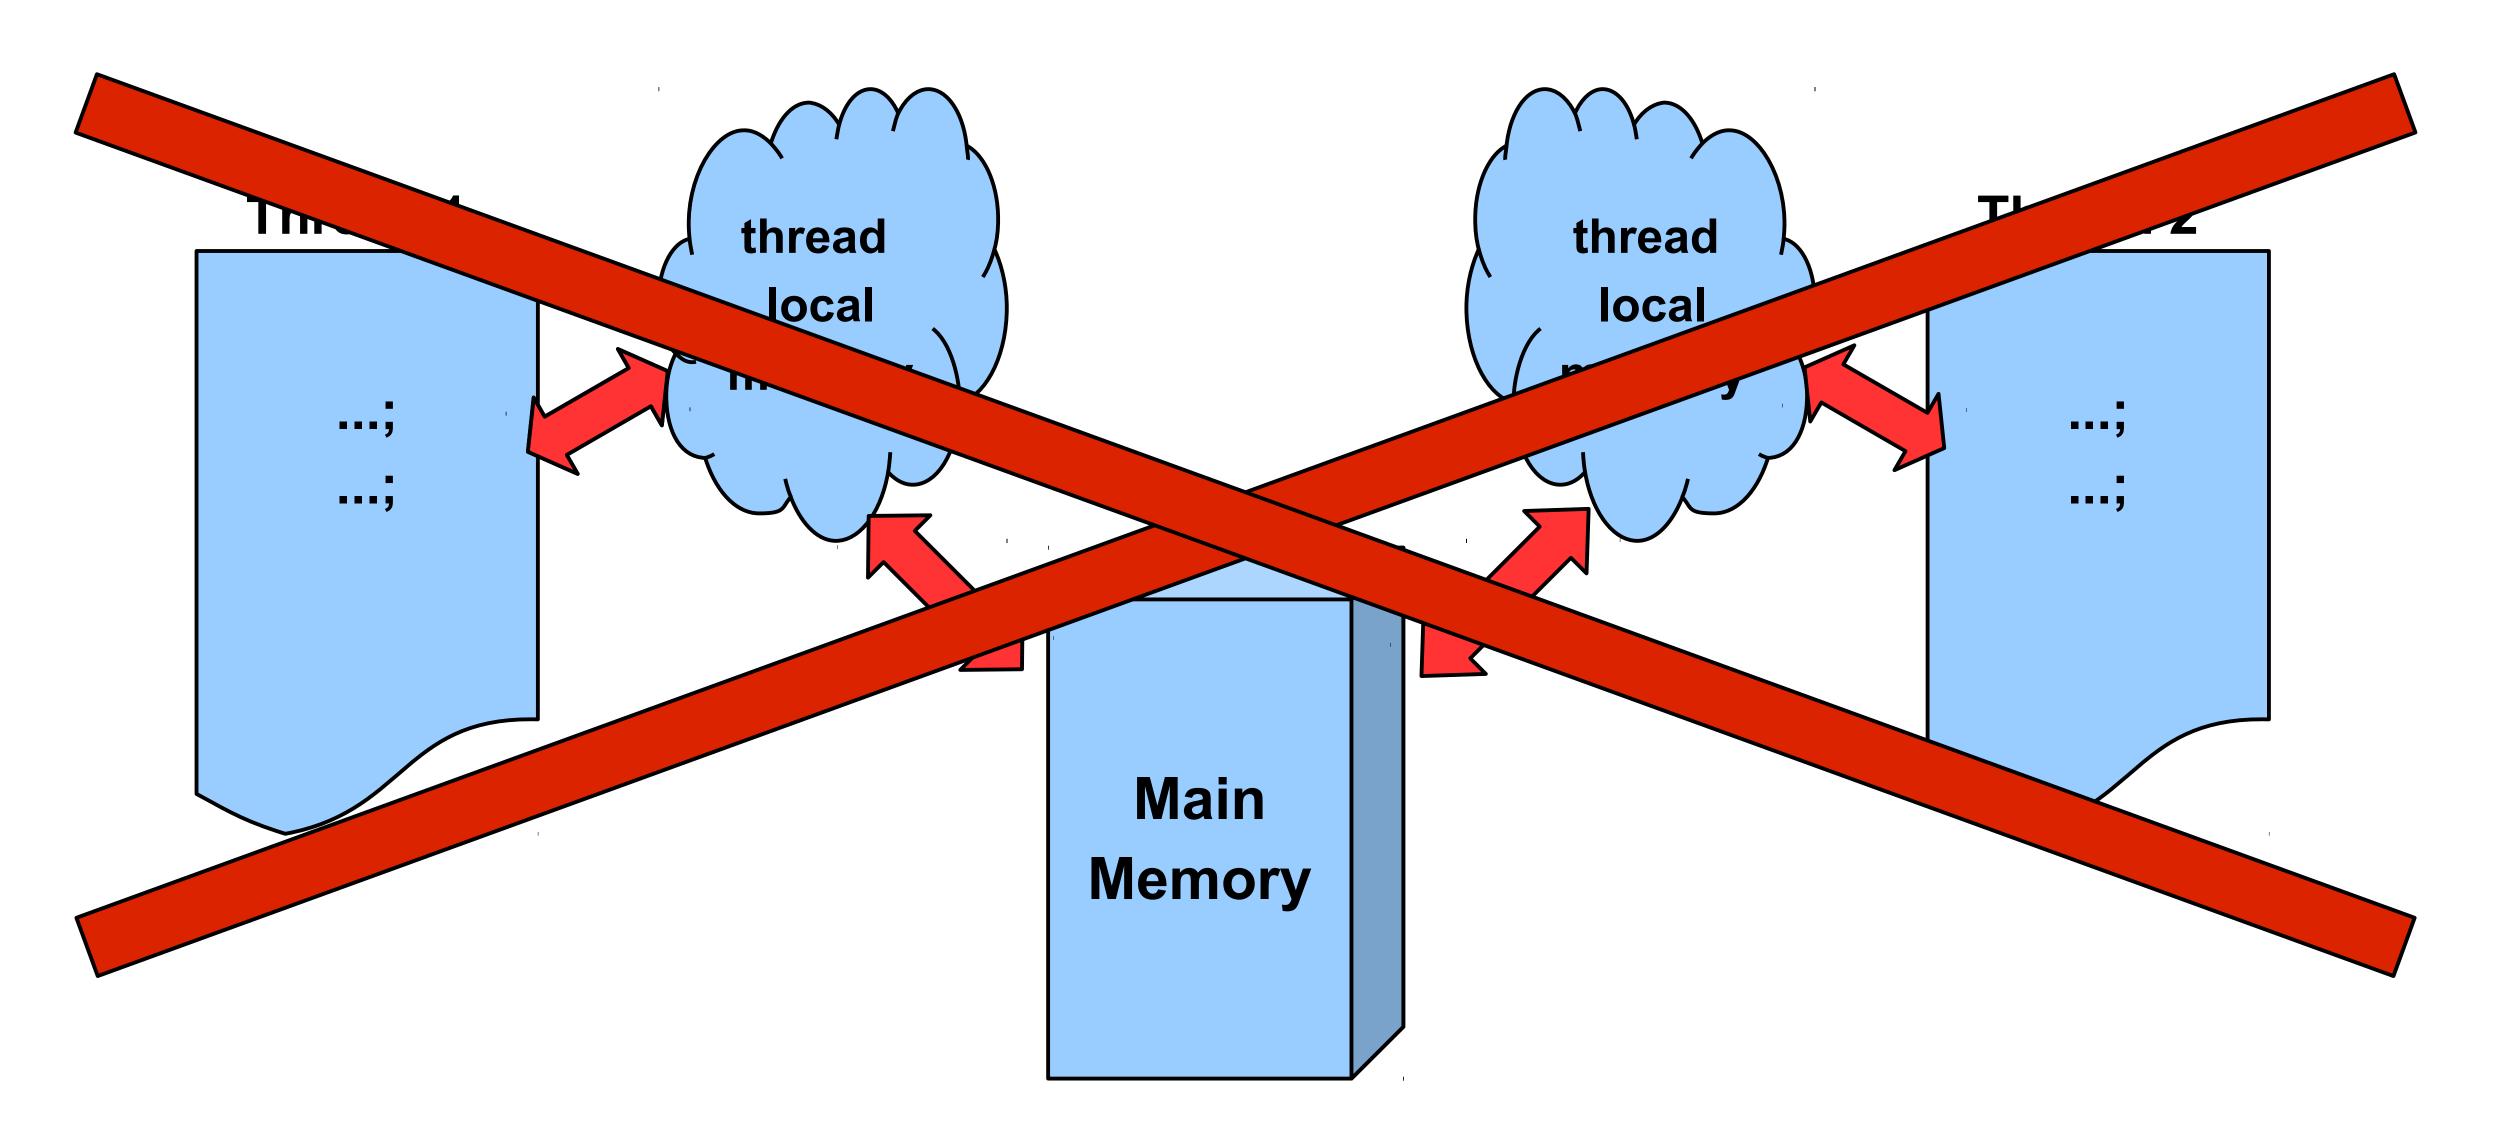


Старая ЈММ





Старая ЈММ



JMM

- Переменные:
 - static field, instance field, array element
- Операции:
 - чтение/запись обычных переменных (read/write)
 - чтение/запись volatile переменных (volatile read/write)
 - синхронизация (lock/unlock)



volatile arrays?

- volatile A[] array;
- volatile не транзитивно:

```
- ...=array;
- volatile read
- array=...;
- volatile write
- array[i]=...;
- обычный write
```

- А если очень нужно?
 - java.util.concurrent.atomic
 (AtomicIntegerArray, AtomicLongArray, AtomicReferenceArray)



• Операции чтения/записи являются атомарными.

- No out of thin-air values:
 - Всякое чтение переменной возвратит либо значение по умолчанию либо значение записанное (где-либо) в эту переменную.



- Исключение:
 - Допускается неатомарное чтение/запись для типов long/double.
 - Чтение/запись volatile long/double обязано быть атомарным.



- Часто встречаемая ошибка:
 - Для volatile long/double **только** операции чтения/записи являются атомарными!
 - -v++, v-- неатомарные операции!
- Что делать?
 - synchronized
 - java.util.concurrent.atomic



Visibility

• Отношение happens-before:

– Если *X happens-before* Y, то X выполнится раньше и Y будет видеть результат X.



Visibility (happens-before в пределах потока)

• В пределах одного потока:

– Все операции имеют отношение happens-before в соответствии с program order



Visibility (happens-before)

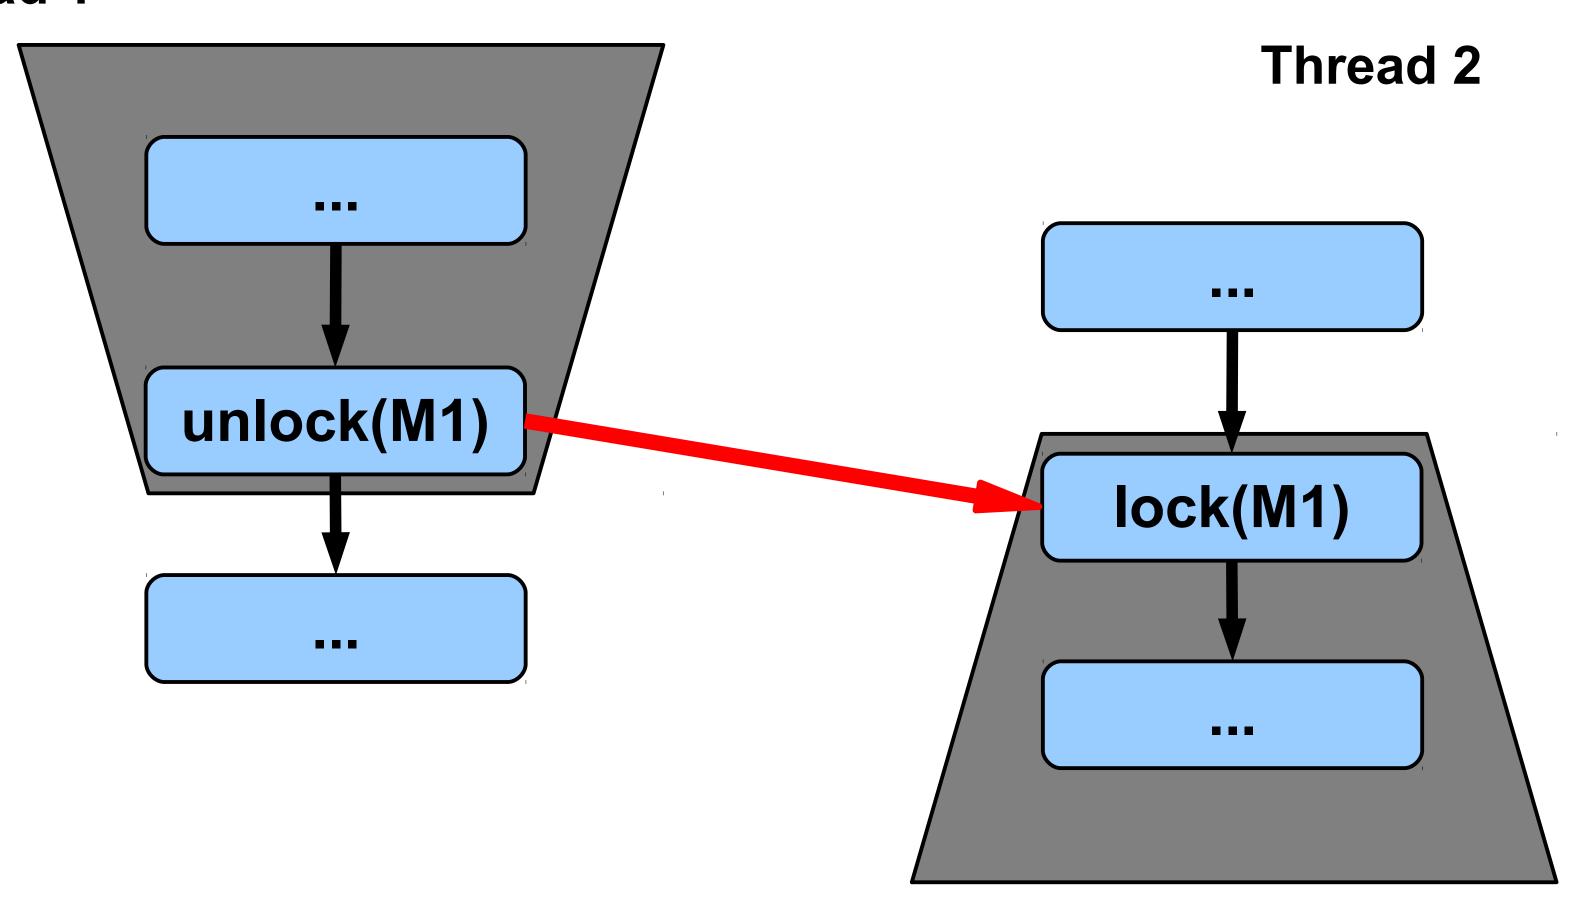
• happens-before транзитивно:

– Если *X happens-before Y и Y happens-before Z*, то *X happens-before Z*.



Visibility (happens-before между потоками)

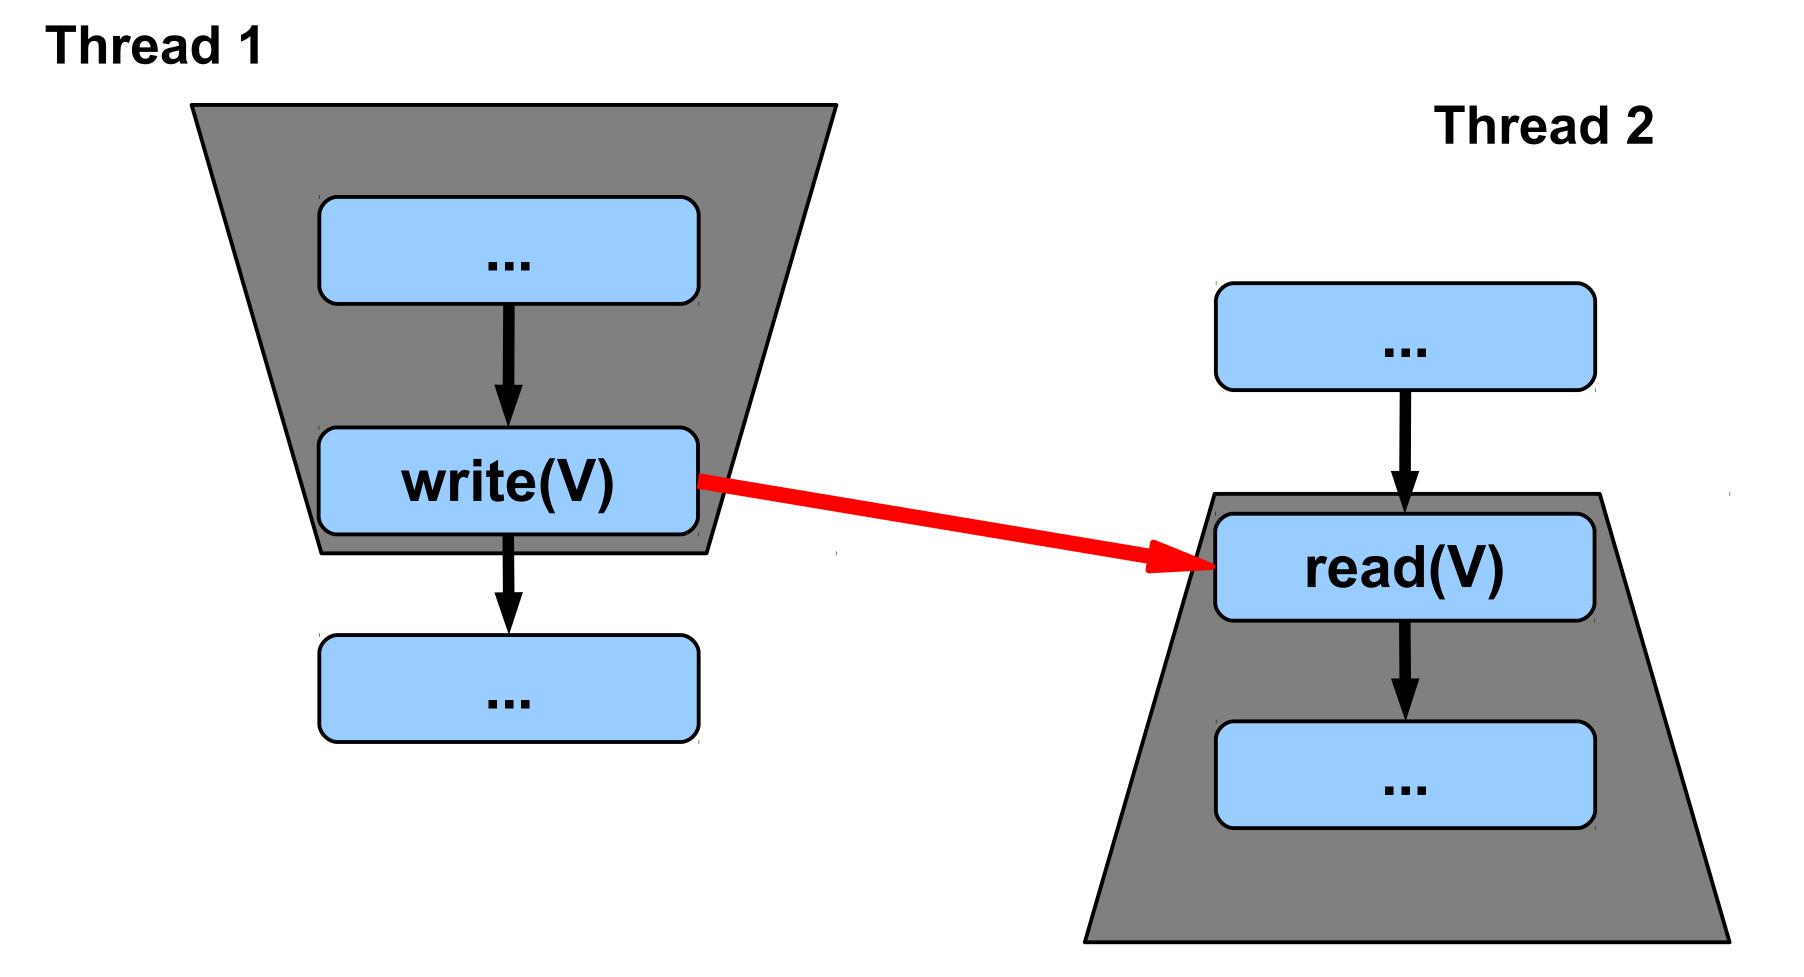
Thread 1



На одном и том же мониторе!



Visibility (happens-before между потоками)



V - volatile

На одной и той же переменной!



Visibility (happens-before между потоками)

- thread.start() → первое действие в потоке
- Последнее действие в потоке \rightarrow join(), isAlive()
- Запись *default value* в любую переменную → первое действие в потоке



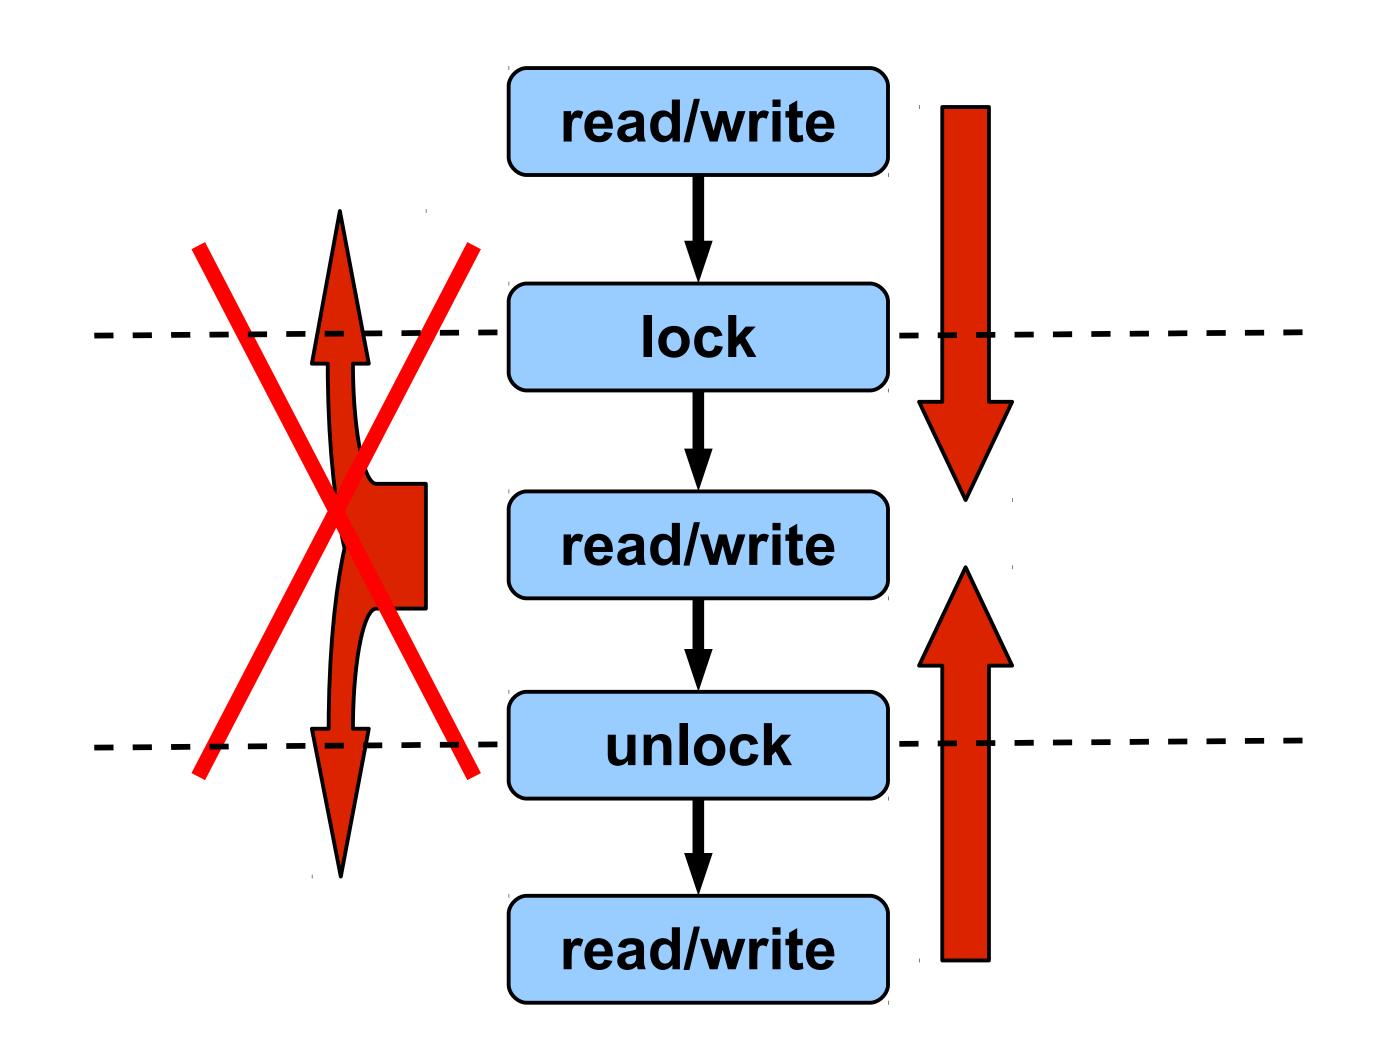
Reordering

- Допустимые перестановки внутри одного треда:
 - Обычные read/write с точностью до зависимости по данным.

• Volatile read/write и lock/unlock не могут переупорядочиваться.



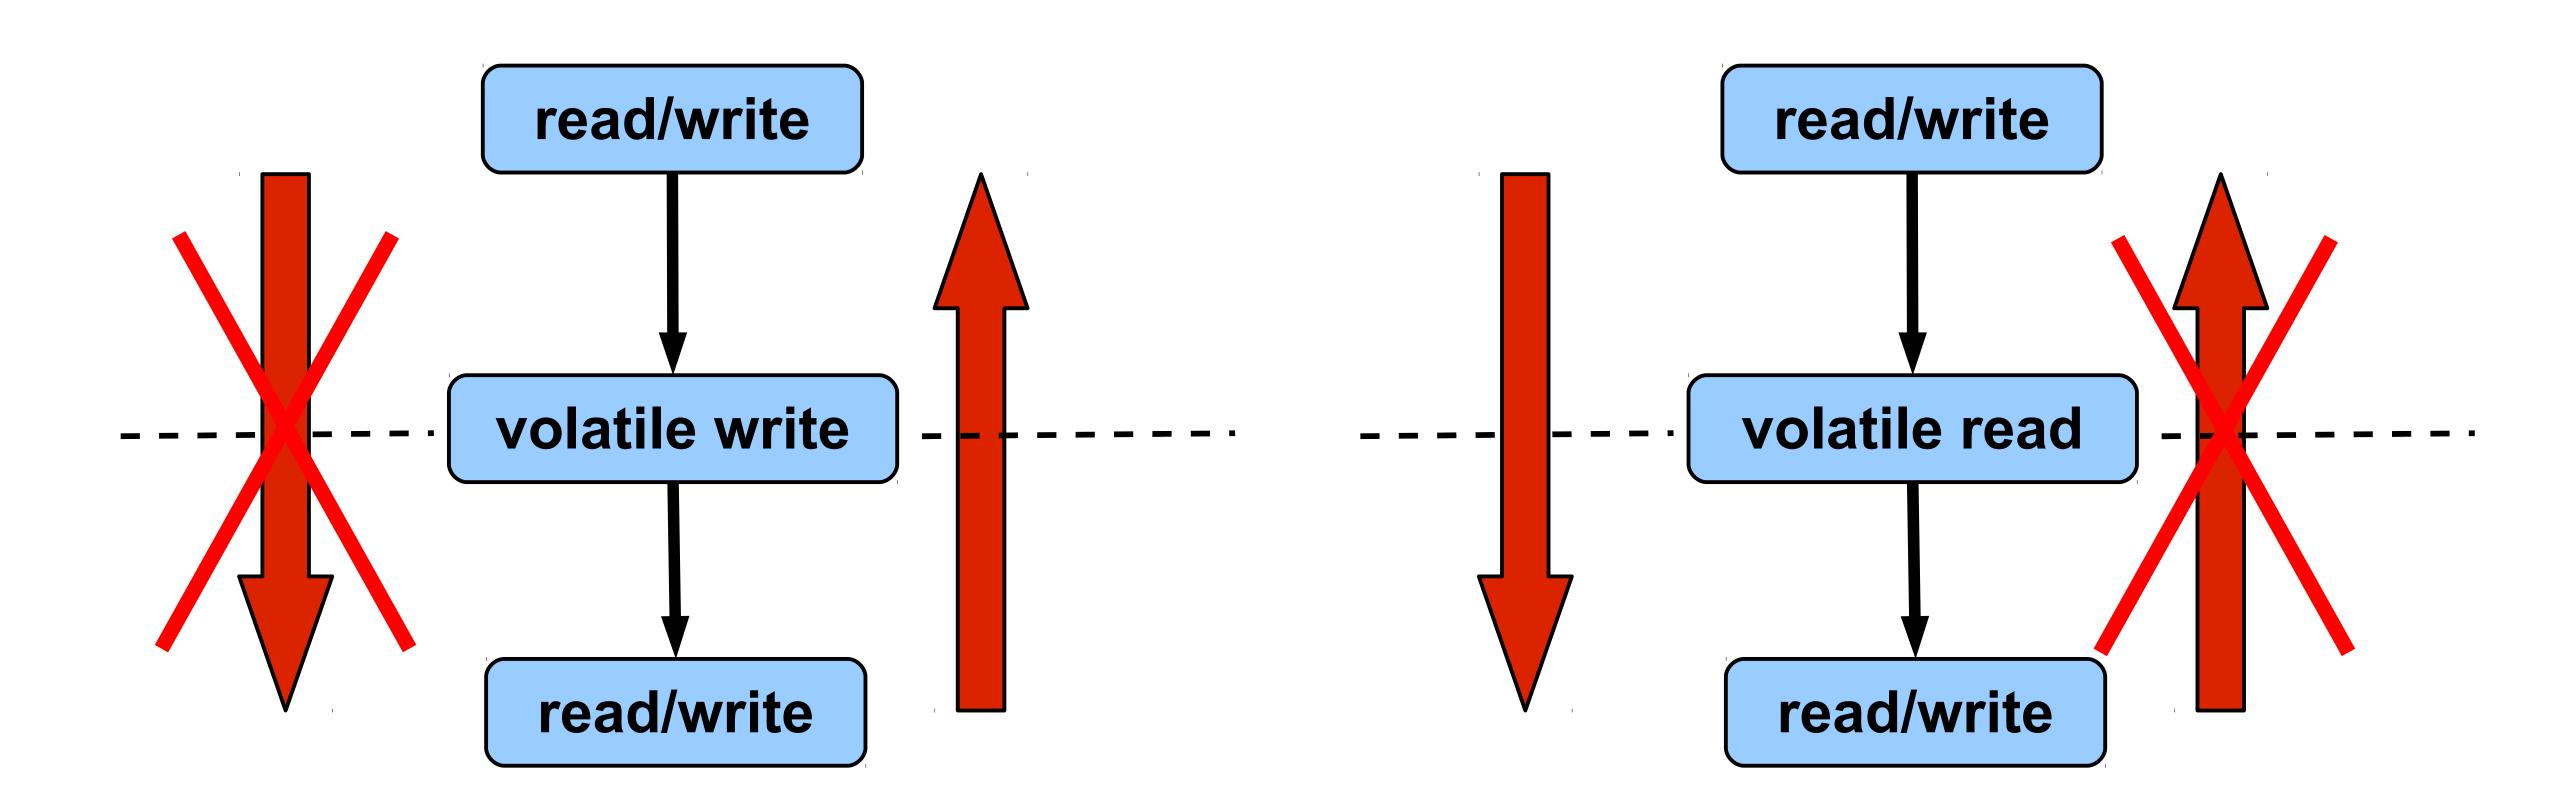
Reordering



Roach motel



Reordering





Начальные значения:

```
int A = 0;
boolean ready = false;
```

Thread 1	Thread 2
<pre>A = 41; A = 42; ready = true; A = 43;</pre>	<pre>while(!ready); System.out.println(A);</pre>

- ничего
- 0
- 41
- 42
- 43



Начальные значения:

```
int A = 0;
boolean ready = false;
```

Thread 1	Thread 2
A = 41; $A = 42;$	<pre>while(!ready); System.out.println(A);</pre>
ready = true;	
A = 43;	

```
- ничего +
- 0 +
- 41 +
- 42 +
- 43 +
```



Начальные значения:

```
int A = 0;
volatile boolean ready = false;
```

Thread 1	Thread 2
<pre>A = 41; A = 42; ready = true; A = 43;</pre>	<pre>while(!ready); System.out.println(A);</pre>

- ничего
- 0
- 41
- 42
- 43



Начальные значения:

```
int A = 0;
volatile boolean ready = false;
```

Thread 1	Thread 2
<pre>A = 41; A = 42; ready = true; A = 43;</pre>	<pre>while(!ready); System.out.println(A);</pre>

- ничего
- --
- 41
- 42 +
- 43 +



Специальная семантика final полей

```
class A {
  final B ref;
  public A(...){
    this.ref=...;
```

- После завершения конструктора любой тред видит значения записаные в *final* поле
 - а также все дерево объектов начиная с этого поля (dereference-chain).



Специальная семантика final полей

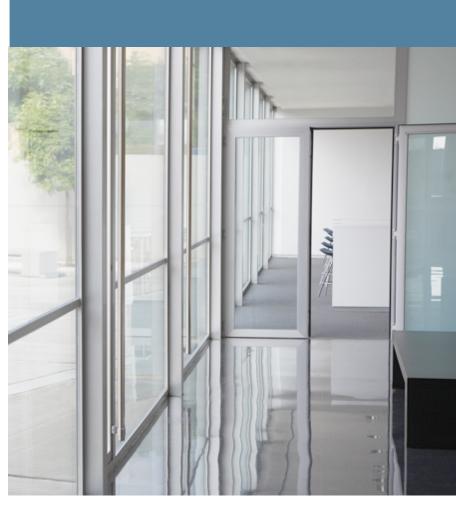
```
class A {
  final B ref;
  public A(...){
    this.ref=...;
```

- Требуется *this* не должен убегать (escape) из конструктора.
 - e.g. регистрация *listener* в его-же конструкторе.
- Модификации в final dereference-chain выполненные после завершения конструктора подчиняются обычным правилам видимости.



Agenda

- Для чего?
- Из-за чего?
- Как
- Примеры
- Сколько стоит





Double-checked locking

```
class Foo {
    private Helper helper = null;
    public Helper getHelper() {
        if (helper == null)
            synchronized(this) {
                if (helper == null)
                    helper = new Helper();
        return helper;
```



Double-checked locking

```
class Foo {
    private volatile Helper helper = null;
    public Helper getHelper() {
        if (helper == null)
            synchronized(this) {
                if (helper == null)
                    helper = new Helper();
        return helper;
```



Double-checked locking (is it correct?)

```
class Foo {
   private static volatile List<A> list = null;
   public static List<A> getList() {
        if (list == null)
            synchronized(Foo.class) {
                if (list == null)
                    list = new ArrayList<A>();
                    list.add(...); list.add(...);
        return list;
```



Yet another fail

```
class Foo {
    private A something;
    public synchronized void setSomething(B b) {
        A a = evaluate_A_from_B();
        this.something = a;
    public A getSomething() {
        return this.something;
```



Yet another fail (fix 1)

```
class Foo {
    private A something;
    public synchronized void setSomething(B b) {
        A a = evaluate_A_from_B();
        this.something = a;
    public synchronized A getSomething() {
        return this.something;
```



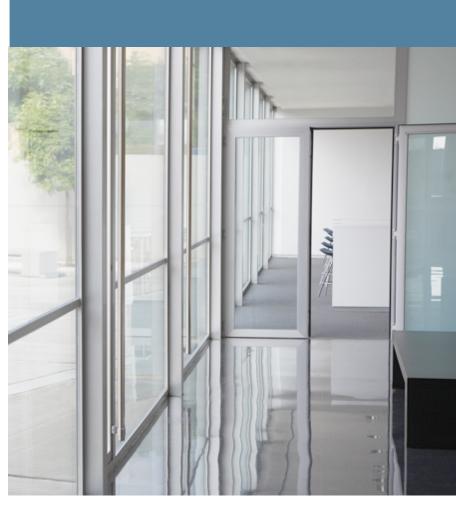
Yet another fail (fix 2)

```
class Foo {
    private volatile A something;
    public synchronized void setSomething(B b) {
        A a = evaluate_A_from_B();
        this.something = a;
    public A getSomething() {
        return this.something;
```



Agenda

- Для чего?
- Из-за чего?
- Как
- Примеры
- Сколько стоит





Производительность

- Как измерить скорость volatile read/write?
 - Влияние HW memory model
 - Влияние на оптимизации компилятора
- x86:
 - volatile read == обычный read
 - volatile write?



Тест 1

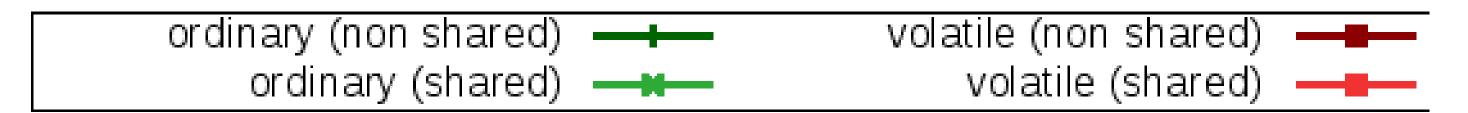
Тест не измеряет ничего реального 1 operation :

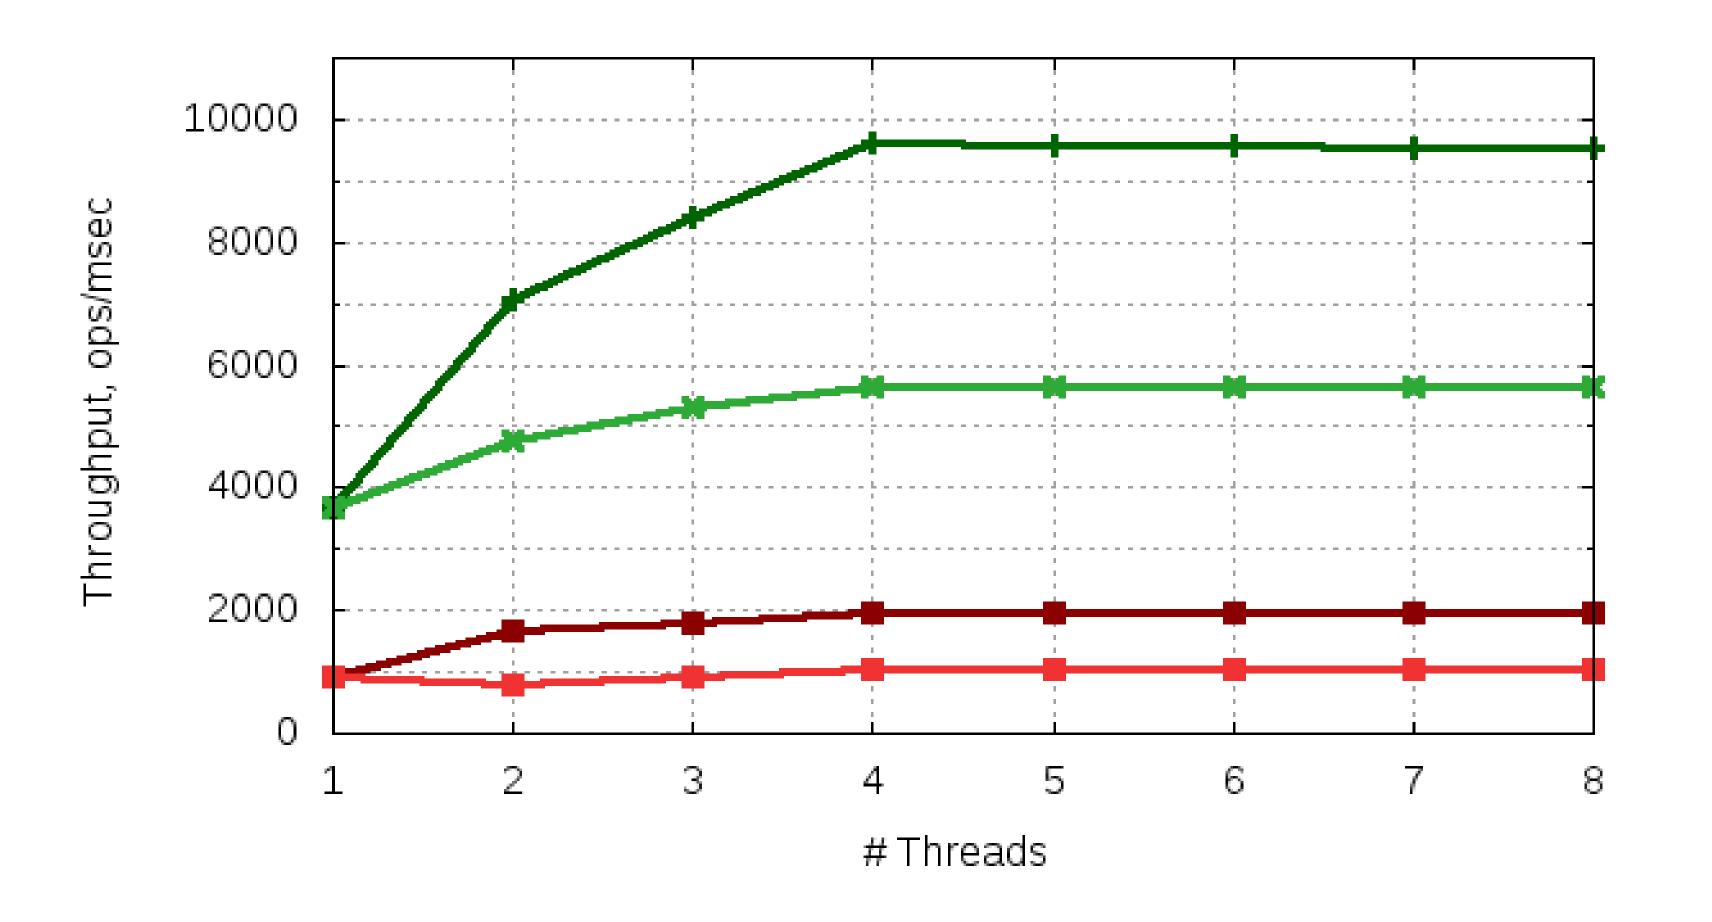
```
for(...) { //128 times
    v = arr[i]++;
}
```

- 129 операций чтения (всегда non-shared, thread local)
- 128 операций записи (всегда non-shared, thread local)
- немного арифметики
- 128 операций записи (4 варианта теста):
 - shared / non shared
 - volatile / non volatile



i5 (2 core, +HT) = 4 HW threads

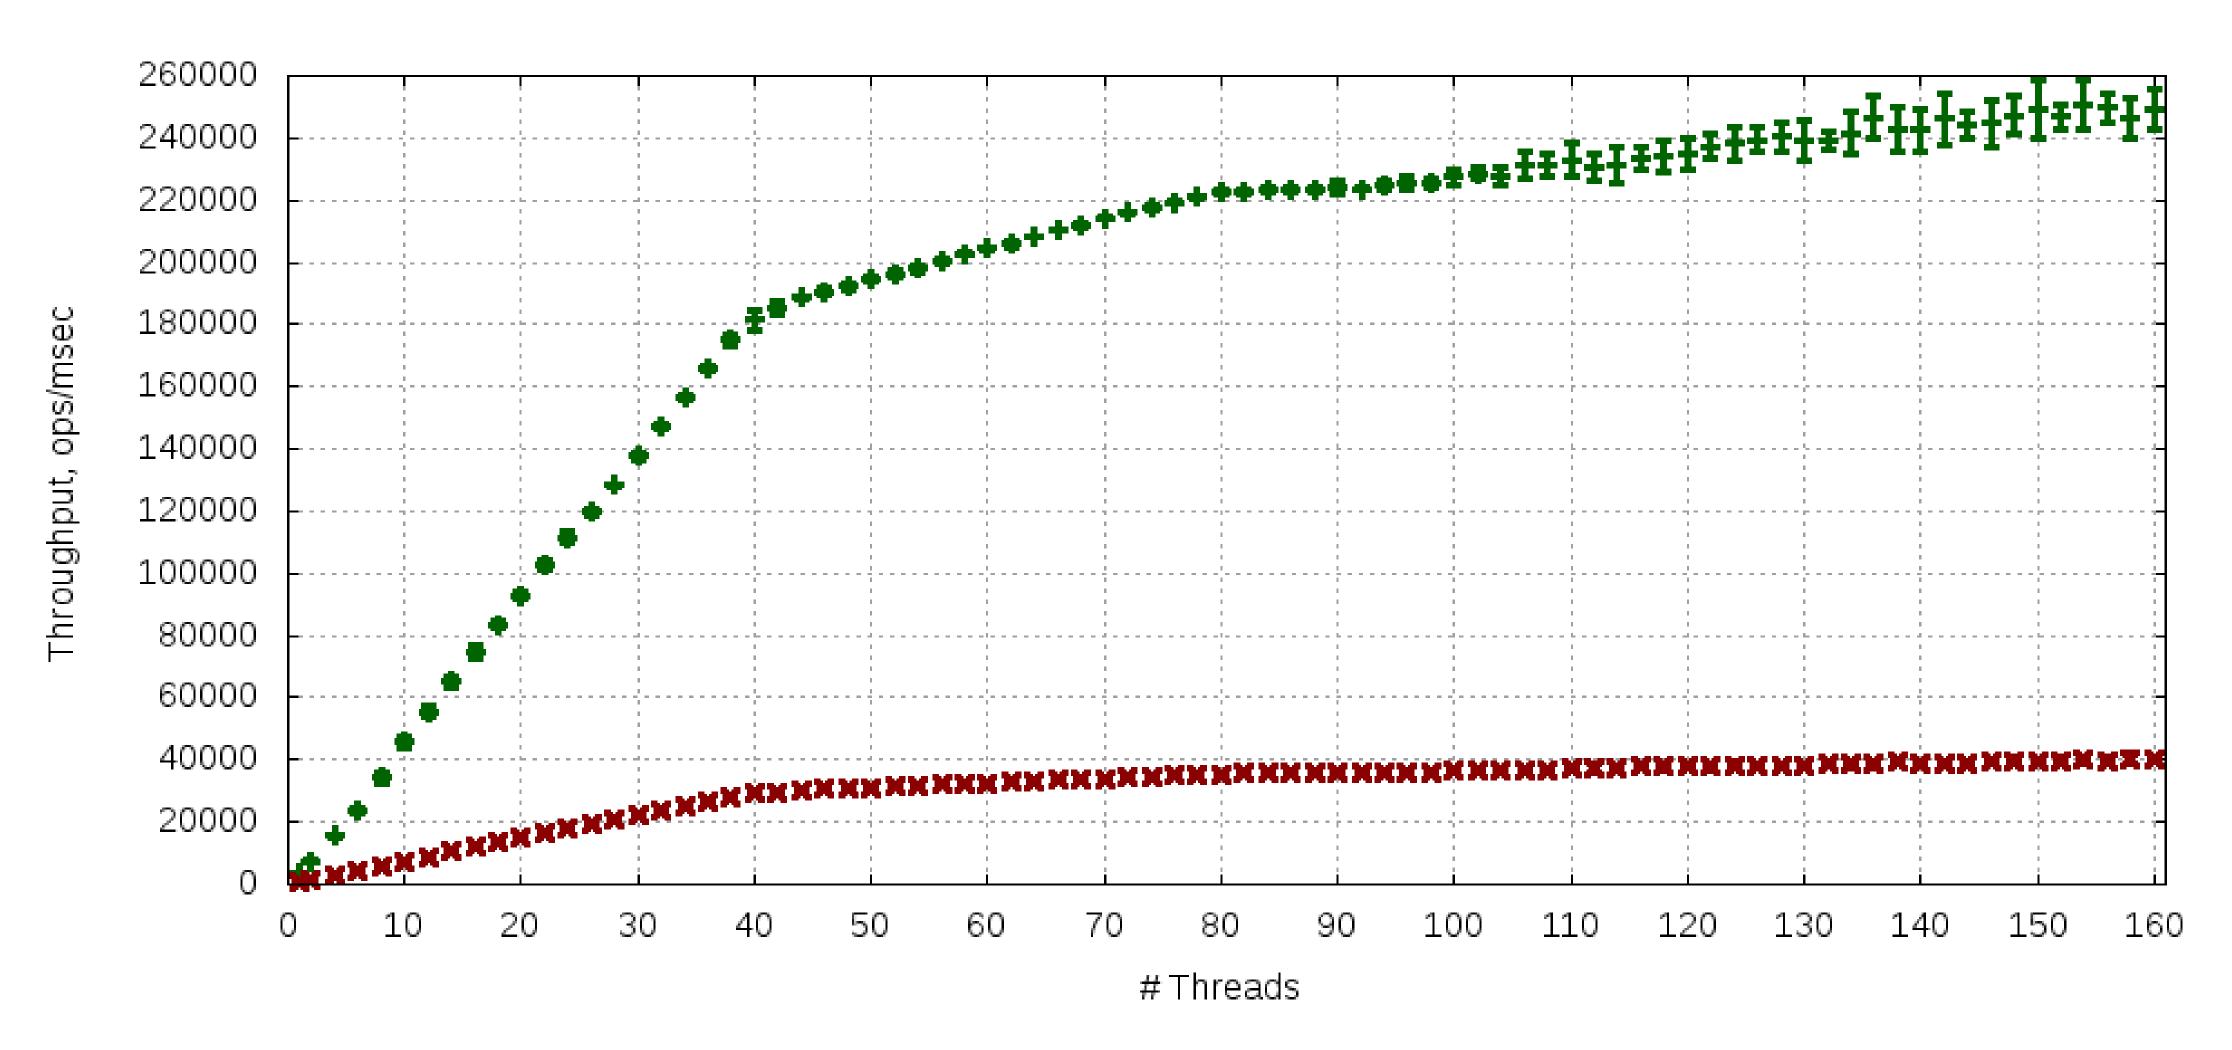






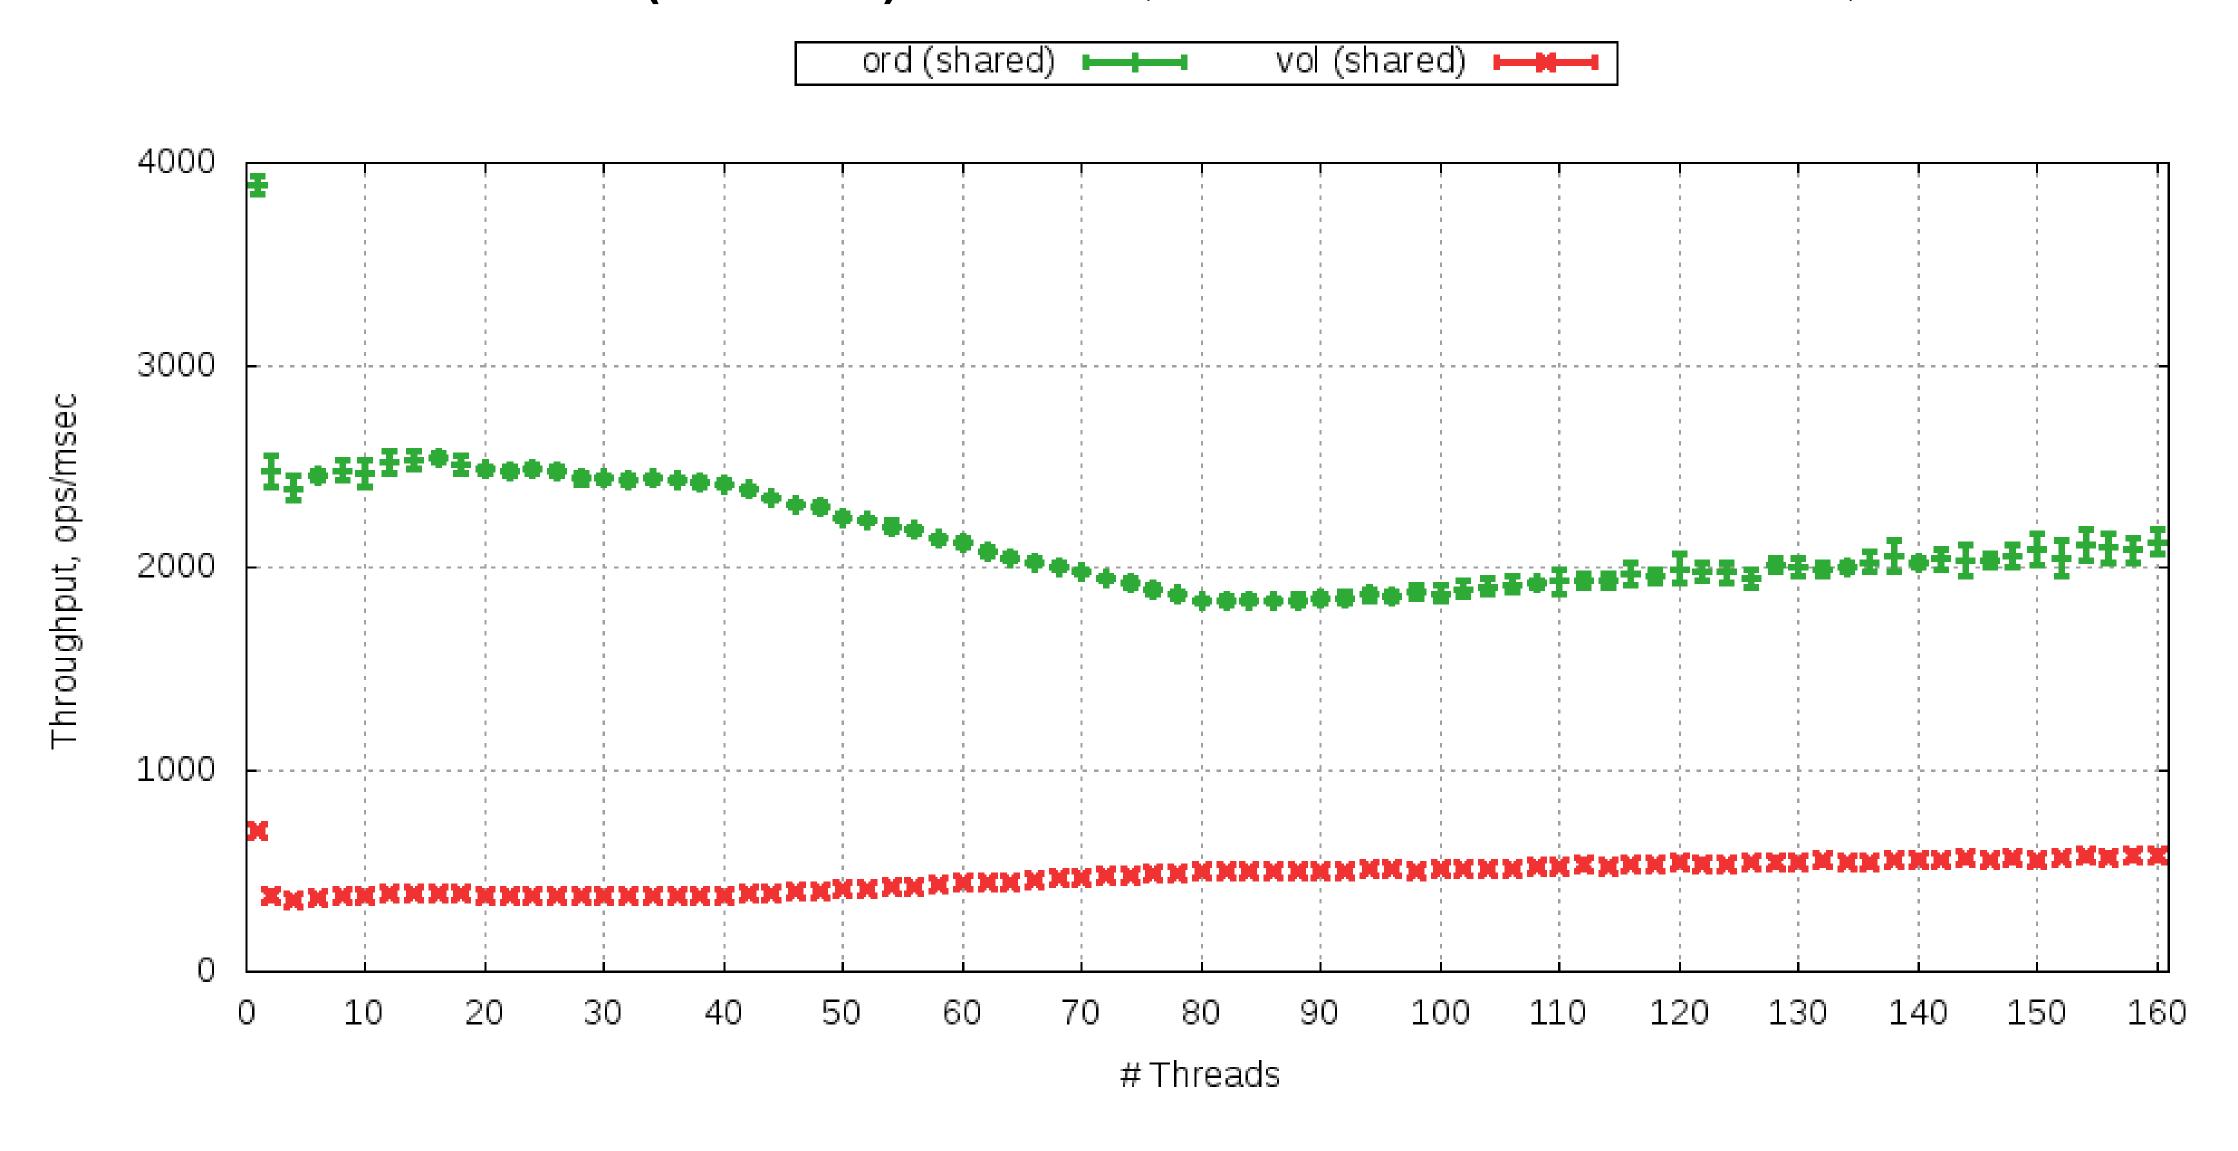
Intel Westmere-EX (E7-4860) 2.27Ghz, 4x10x2 = 80 HW threads, RHEL 5.5





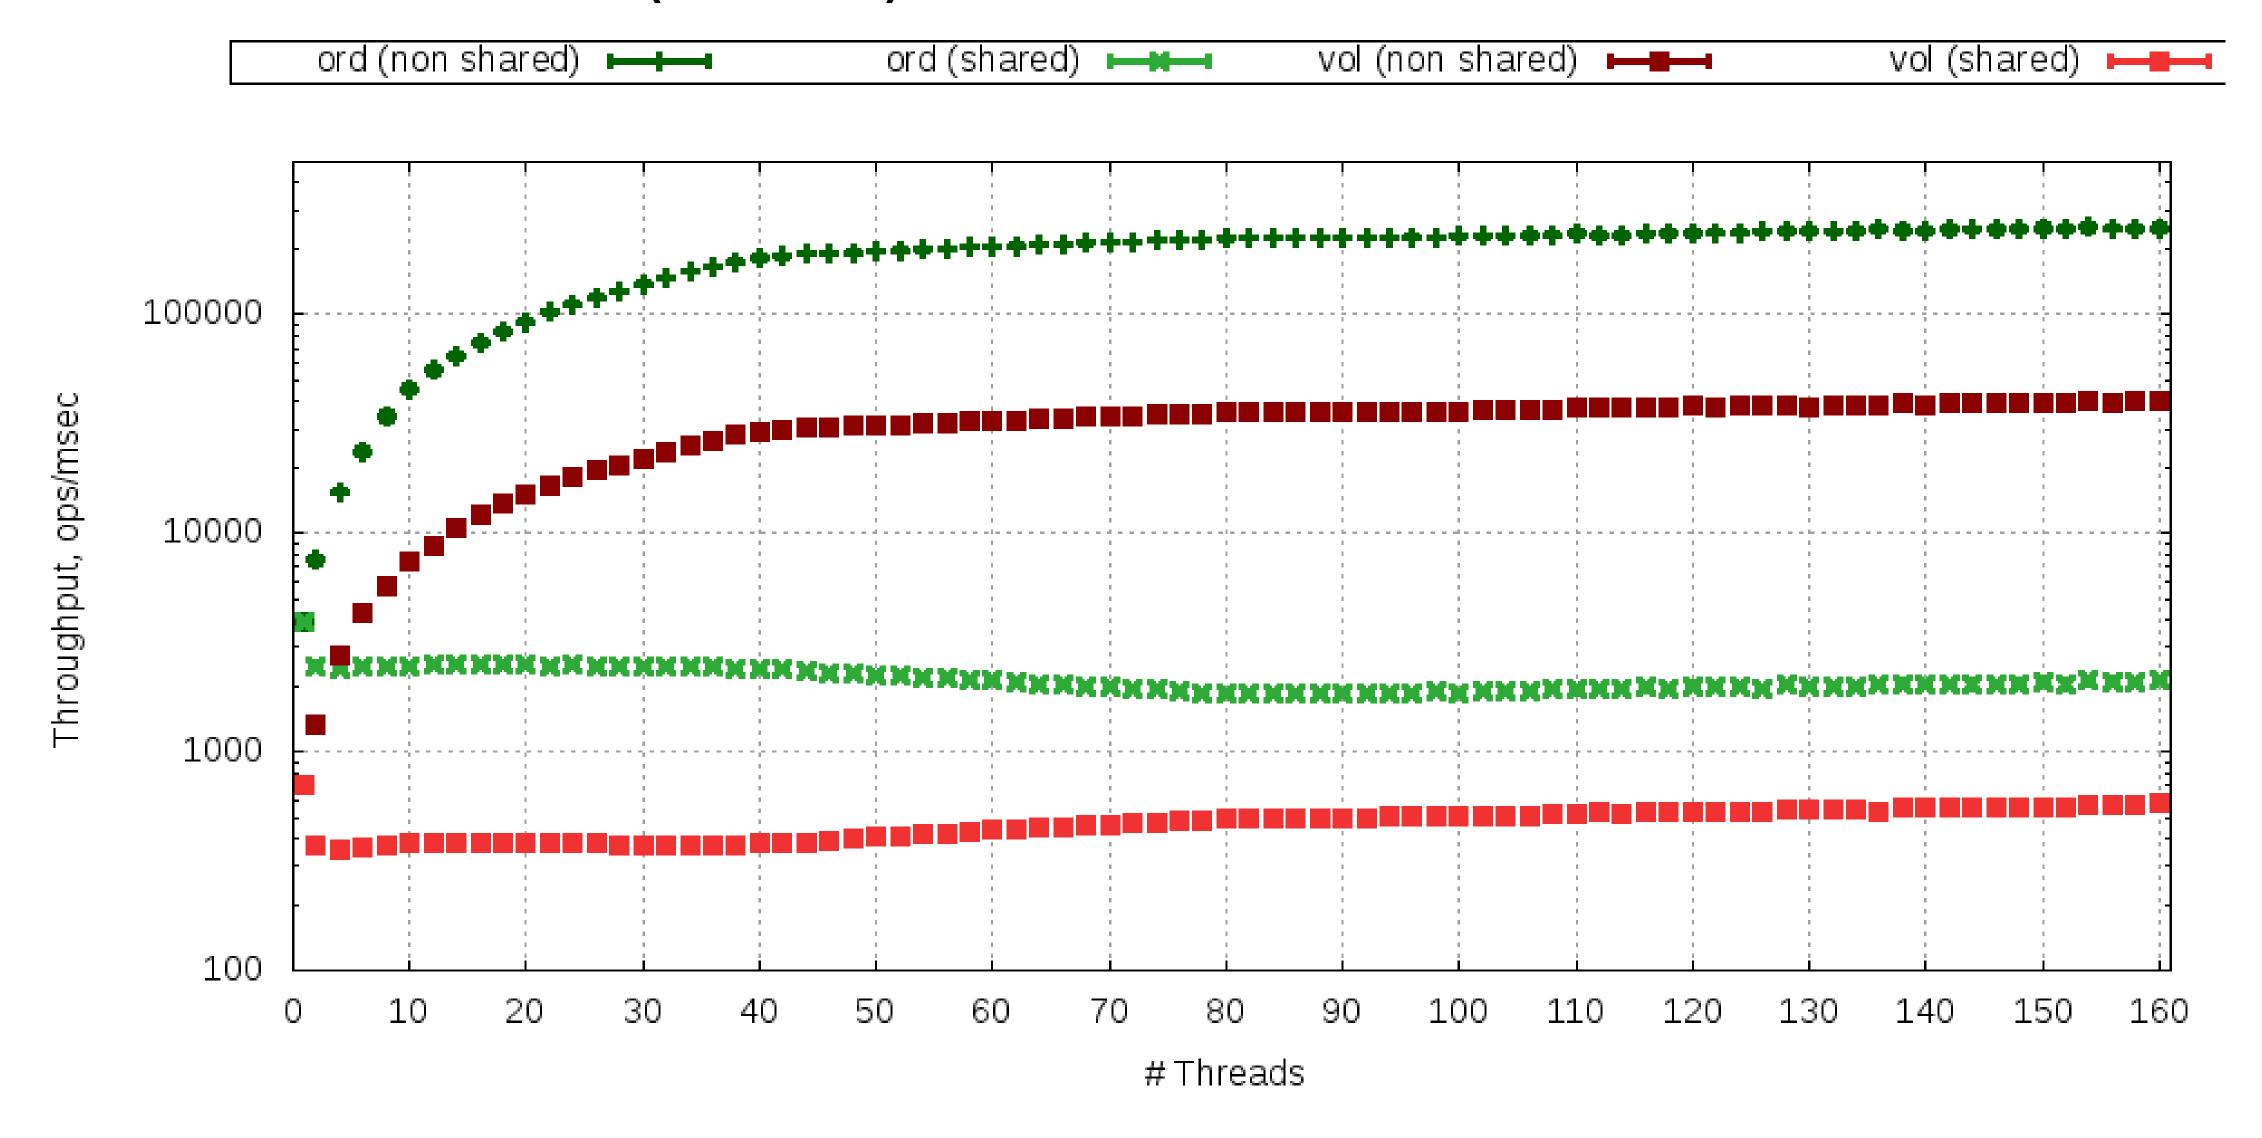


Intel Westmere-EX (E7-4860) 2.27Ghz, 4x10x2 = 80 HW threads, RHEL 5.5





Intel Westmere-EX (E7-4860) 2.27Ghz, 4x10x2 = 80 HW threads, RHEL 5.5





Тест 2

```
private int[] array = new int[10000];
...

public int test(){
   int s = 0;
   for(int i=0; i<array.length; i++) {
      s+=array[i];
   }
   return s;
}</pre>
```



Тест 2 (rev. 1)

```
private int[] array = new int[10000];
...

public int test(){
   int s = 0;
   for(int i=0; i<array.length; i++) {
      s+=array[i];
   }
   return s;
}</pre>
```

Throughput = 495 ops/msec



Тест 2 (rev. 2)

```
private volatile int[] array = new int[10000];
...
public int test(){
   int s = 0;
   for(int i=0; i<array.length; i++) {
       s+=array[i];
   }
   return s;
}</pre>
```

i5 (2 core, +HT) = 4 HW threads

Throughput = 62 ops/msec



Тест 2 (rev. 3)

```
private volatile int[] array = new int[10000];
• • •
public int test(){
   int s = 0;
   int[] a = array;
   for(int i=0; i<a.length; i++) {</pre>
       s+=a[i];
   return s;
```

$$i5 (2 core, +HT) = 4 HW threads$$

Throughput = 495 ops/msec



Читаем

- "Java Concurrency in Practice", Brian Goetz, Tim Peierls, Joshua Bloch, Joseph Bowbeer, David Holmes, Doug Lea
- "The Art of Multiprocessor Programming", Maurice Herlihy, Nir Shavit
- "JSR 133 Cookbook"
 - http://g.oswego.edu/dl/jmm/cookbook.html
- "Memory Barriers: a Hardware View for Software Hackers", Paul E. McKenney
- "What Every Programmer Should Know About Memory", Ulrich Drepper
 - http://www.akkadia.org/drepper/cpumemory.pdf





Q&A?

